

目标检测算法综述

憨芳静¹⁾ *

¹⁾ 南京邮电大学计算机学院南京 210023

摘 要 目标检测作为计算机视觉中最基本、最具挑战性的问题之一,受到了极大的关注。近年来,目标检测技术的快速发展及其对整个计算机视觉领域的深远影响。如果我们把今天的物体检测技术看作是一场由深度学习驱动的革命,看到了早期计算机视觉的巧妙思维和长远设计。本文涵盖了许多主题,包括历史上的检测器、检测数据集、度量、检测系统的基本构建块、加速技术、最近最先进的检测方法,对多个模型进行了对比实验,并对未来工作做了一些展望。

关键词 目标检测; 卷积神经网络; 计算机视觉; 模型架构

中图法分类号 TP **DOI 号:** * 投稿时不提供 DOI 号

A Survey of Object Detection Algorithms

Han Fangjing¹⁾

¹⁾(College of Computer, Nanjing University of Posts and Telecommunications, Nanjing, 210023)

Abstract As one of the most basic and challenging problems in computer vision, object detection has received great attention in recent years. In recent years, the rapid development of object detection technology and its far-reaching impact on the entire field of computer vision. If we regard today's object detection technology as a revolution driven by deep learning, we saw the ingenious thinking and long-term design of early computer vision. This article covers many topics, including historical detectors, detection data sets, metrics, the basic building blocks of detection systems, acceleration technologies, and the most advanced detection methods recently. The comparative experiments of several models are carried out, and the future work is prospected.

Keywords Target detection; Convolutional neural network; Computer vision; model architecture

1 引言

自从 1956 年人工智能 (Artificial Intelligence, AI) 的概念被首次提出以来^[1], 它经历了多个阶段的演变和突破。随着计算能力的提升和海量的数据集积累, 人工智能已经成为科技发展和产业变革的核心驱动力, 在医疗诊断、军事、自动驾驶等诸多领域发挥了不可或缺的作用。其中, 计算机视觉作为人工智能的重要分支, 旨在使计算机达到人类或者胜于人类的视觉信息感知、理解和分析能力, 涵

盖了图像处理、目标检测与识别、目标跟踪、三维视觉场景理解等多个研究方向。近年来依托于深度学习的迅猛发展, 计算机视觉研究领域取得了显著进展, 尤其在目标检测、人脸识别和大规模图像分类等特定任务上, 其性能表现已经超越了人类视觉系统。计算机视觉领域的研究成果为解决现实问题、改善生产生活方式以及推动产业升级提供了技术保障和理论依据, 同时对社会的智能化进程提供了有力支撑。

* 憨芳静, 女, 2003 年生, 硕士, 主要研究领域为图联邦学习. E-mail: 1025040703@njupt.edu.cn.

视觉目标检测 (Visual Object Detection, VOD) 作为计算机视觉领域的一项关键任务, 旨在为各类计算机视觉应用程序提供两项最基础的关键信息: 识别目标“是什么”和“在哪里”? 目标检测的两个最重要的指标是准确性 (包括分类准确性和定位准确性) 和速度。

目标检测是许多其他计算机视觉任务的基础, 如实例分割^[2-5]、图像字幕^[6-8]、目标跟踪^[9]乃至视频理解等。近年来, 深度学习技术^[10]的快速发展极大地推动了目标检测的进步, 取得了显著突破, 并使其成为前所未有的研究热点。目标检测现在已被广泛应用于许多现实世界的应用中, 如自动驾驶场景中的目标识别和环境感知, 安防领域内的车牌识别、人脸检测、X-ray 识别, 工业场景下的部件缺陷检测以及医疗领域的细胞病理诊断检测和肿瘤分割与检

测等。

由于不同的检测任务具有完全不同的目标和约束, 因此它们的难度可能各不相同。除了其他计算机视觉任务中的一些常见挑战, 如不同视点、光照和类内变化下的对象, 目标检测中的挑战还包括但不限于以下几个方面: 对象旋转和比例变化 (例如小对象)、精确的对象定位、密集和遮挡的目标检测、检测速度等。

本次调查旨在从多个角度为新手提供对目标检测技术的完整知识体系, 重点是技术的发展脉络。站在技术高速公路上, 这项调查旨在呈现相关技术的演变, 依托于人工智能 (尤其是深度学习) 的发展历程, 按照不同的基础模型, 包括卷积神经网络、Transformer, 进行分类介绍, 为读者提供了一个清晰的历史和技术脉络, 并找到潜在的未来方向。

2 目标检测算法概述

2.1 传统算法

目标检测的进展大致经历了两个历史时期: “传统目标检测时期 (2014 年之前)” 和 “基于深度学习的检测时期 (2015 年之后)”。如果我们把今天的物体检测技术看作是深度学习驱动的一场革命, 那么早在 20 世纪 90 年代, 我们就会看到早期计算机视觉的巧妙设计和长远前景。早期的大多数目标检测算法都是基于手工特征构建的。由于当时缺乏有效的图像表示, 人们不得不设计复杂的特征表示和各种加速技术。

Viola Jones 检测器: 2001 年, P.Viola 和 M.Jones 首次实现了人脸的实时检测, 没有任何约束 (例如肤色分割)^[11-12]。该检测器在 700MHz Pentium III CPU 上运行, 在可比的检测精度下, 其速度比当时的其他算法快数十甚至数百倍。VJ 检测器遵循一种最直接的检测方法, 即滑动窗口: 遍历图像中所有可能的位置和比例, 查看是否有任何窗口包含人脸。虽然这似乎是一个非常简单的过程, 但它背后的计算远远超出了当时计算机的能力。VJ 检测器通过结合三种

重要技术大大提高了其检测速度: “积分图像”、“特征选择” 和 “检测级联”。

HOG 检测器: 2005 年, N.Dalal 和 B.Triggs 提出了面向梯度直方图 (HOG) 特征描述符^[13]。HOG 可以被认为是对其时代尺度不变特征变换^[14-15]和形状背景^[16]的重要改进。为了平衡特征不变性 (包括平移、缩放、照明等) 和非线性, HOG 描述符被设计为在均匀间隔的密集网格上计算, 并使用重叠的局部对比度归一化。虽然 HOG 可用于检测各种对象类别, 但其主要动机是行人检测问题。为了检测不同大小的物体, HOG 检测器多次重新缩放输入图像, 同时保持检测窗口的大小不变。多年来, HOG 探测器一直是许多物体探测器^[17-19]和各种计算机视觉应用的重要基础。

基于变形部分的模型 (DPM): DPM 作为 VOC-07、-08 和 -09 检测挑战的获胜者, 是传统目标检测方法的缩影。DPM 最初由 P.Felzenszwalb^[17]于 2008 年提出, 作为 HOG 探测器的扩展。它遵循“分而治之”的检测哲学, 其中训练可以简单地被视为学习分解对象的正确方法, 推理可以被视为对不同对象部分的检测的集合。例如, 检测“汽车”的问题可以

分解为检测其车窗、车身和车轮。这部分工作，也称为“恒星模型”。后来，R.Girshick 将恒星模型进一步扩展为“混合模型”，以处理现实世界中更显著变化下的物体，并进行了一系列其他改进^[18,20-22]。

2.2 基于卷积神经网络（CNN）的方法

随着手工制作特征的性能饱和，物体检测的研究在 2010 年后达到了一个停滞期。2012 年，世界见证了卷积神经网络^[23]的重生。由于深度卷积网络能够学习图像的鲁棒性和高级特征表示，一个自然的问题出现了：我们能把它引入到目标检测中吗？

R.Girshick 等人在 2014 年提出的 R-CNN^[24]首次给出了肯定答案，打破了僵局，开启了目标检测的深度学习时代。自此，检测器主要沿着两大技术范式演进：“两阶段检测器”遵循“从粗到细”的流程，首先生成候选区域，再进行精细分类与定位；而“一阶段检测器”则追求“一步到位”，直接在图像上进行密集预测，以实现更高的速度。

RCNN: RCNN 为开创性工作，其流程直观：先通过选择性搜索提取约 2000 个候选区域，将每个区域缩放后送入预训练的 CNN（如 AlexNet^[25]）提取特征，最后使用一组 SVM 进行分类。R-CNN 在 PASCAL VOC07 上将平均精度（mAP）从 33.7%（DPM-v5）大幅提升至 58.5%^[24,26]。但其缺点显：对每个候选区域独立进行特征提取导致巨大计算冗余，GPU 处理单张图像需约 14 秒。SPP-Net: 同年晚些时候，针对 R-CNN 的速度瓶颈，空间金字塔池化网络（spatial pyramid pooling net, SPP-Net）^[27]被提出。其主要贡献是引入了空间金字塔池（SPP）层，该层可将任意大小的区域映射为固定长度特征向量，使得整图只需通过 CNN 一次即可提取所有区域特征，将检测速度提升 20 倍以上且不损失精度。然而，SPP-Net 的训练仍是多阶段的，且未能实现完全的端到端优化。

Fast RCNN: 2015 年，R.Girshick 提出了快速 RCNN 检测器^[28]并解决了这些问题。快速 RCNN 使我们能够在相同的网络配置下同时训练检测器和边界框回归器。在 VOC07 数据集上，FastRCNN 将

mAP 从 58.5% (RCNN) 提高到 70.0%，同时检测速度比 R-CNN 快 200 多倍。尽管 Fast RCNN 成功地整合了 R-CNN 和 SPPNet 的优点，但其检测速度仍然受到提案检测的限制。然后，一个问题自然会出现：“我们能用 CNN 模型生成对象提案吗？”后来，Faster R-CNN^[29]回答了这个问题。

Faster RCNN: 同年不久后，S.Ren 等人提出了更快的 R-CNN^[29]。通过引入了区域建议网络 (RPN)，使区域建议几乎免费。从 R-CNN 到 Faster RCNN，目标检测系统的大多数单个块，例如提案检测、特征提取、边界框回归等，都已逐渐集成到一个统一的端到端学习框架中。

Cascade R-CNN: Cai 等人^[30]后续提出的 Cascade R-CNN 进一步关注检测质量，通过级联多个使用不同 IoU 阈值的检测器对边界框进行逐步精细化修正，显著提升了困难样本的检测精度。

与此同时，一阶段检测器范式因追求极致速度而迅速发展。

YOLO: YOLO 是由 R.Joseph 等人^[31]于 2015 年提出，是首个现代一阶段探测器。它将图像划分为网格，每个网格直接预测目标的边界框和类别概率，检测速度有了很大提高，但与两级探测器相比，它的定位精度有所下降，尤其是小目标检测精度较低。YOLO 的后续版本^[32]和后者提出的 SSD^[33]都更加关注这个问题。最近，YOLOv4 团队的后续工作 YOLOv7^[52]被提出。通过引入动态标签分配和模型结构重新参数化等优化结构，它在速度和精度（范围从 5 FPS 到 160 FPS）方面优于大多数现有的目标检测器。

RetinaNet: 尽管速度快且简单，但单级探测器的精度多年来一直落后于两级探测器。林等人在 2017 年^[34]探索了 RetinaNet 背后的原因并提出了 Retina Net。他们发现，在训练密集探测器时遇到的极端前景背景类不平衡是主要原因。为此，RetinaNet 中引入了一种名为“焦点损失”的新损失函数，通过重塑标准交叉熵损失，使检测器在训练过程中更加关注难以分类的错误示例。使单级探测器能够实现与

两级探测器相当的精度,同时保持非常高的探测速度。

随着两大范式的发展,一些共性的、超越范式本身的关键技术被提出,极大地推动了整体领域的进步。多尺度特征融合的进化是其中的代表。

特征金字塔网络 (FPN): 2017 年,林等人提出了 FPN^[35]。FPN 开发了一种具有横向连接的自上而下的架构,将深层的高语义特征上采样并与浅层的高分辨率特征融合,系统地构建了一个兼具强语义和高分辨率的特征金字塔。FPN 作为一个通用的特征增强模块,迅速被集成到 Faster R-CNN、RetinaNet 等各类检测框架中,成为提升多尺度目标检测性能的标准组件。证明通过合理的感受野设计与匹配策略,仅使用单层特征图也能实现高效的多尺度检测。

YOLOF: 由 Chen 等人^[36]提出,是对 FPN 的一种简化和创新。通过实验证明,FPN 的成功主要归因于不同尺度感受野对不同规模目标的处理能力。YOLOF 基于这一发现,提出无需复杂的多尺度融合,只使用骨干网络的最后一层特征图就能完成检测任务。

在基础框架成熟后,研究者开始探索更简洁、更高效的新设计范式,以克服基于锚框 (Anchor-Based) 方法的固有缺陷。

Tian 等人^[37]提出的 FCOS 则遵循了密集预测思路,将特征图上的每个点视为样本,直接预测其到边界框四边的距离,并引入“中心度”分支来抑制低质量预测,展示了强大的性能。

CornerNet: H.Law 等人^[38]摒弃了之前的检测范式,率先将目标检测定义为关键点 (目标框的角点) 检测与配对问题。在获得关键点后,它将使用额外的嵌入信息对角点进行解耦和重新分组,以形成边界框。CornerNet 的性能优于当时大多数单级探测器。

CenterNet: X.Zhou 等人提出的 Center-Net^[39]进一步简化。将目标建模为单个中心点,并直接从中心点回归目标尺寸,实现了更简洁的端到端流程。

2.3 基于 Transformer 架构的方法

近年来,Transformers 深刻地影响了整个深度学习领域,特别是计算机视觉领域。变换器摒弃了传统的卷积算子,转而采用单注意计算,以克服卷积神经网络的局限性,获得全局尺度的接收场。

DETR: 2020 年,N.Carion 等人提出了 DETR^[40],他们将目标检测视为一个集合预测问题,并提出了一个带有 Transformers 的端到端检测网络。到目前为止,物体检测已经进入了一个新时代,在这个时代,物体可以在不使用锚箱或锚点的情况下被检测到。DETR 也有局限,如训练速度慢,对小目标检测的性能较差。

Deformable DETR: Zhu 等人^[41]率先做出改进,结合可变形卷积的稀疏空间采样和 Transformer 的关系建模能力的优点,提出了 Deformable DETR。它引入了可变形注意力模块,该模块只关注参考点周围少量关键采样点,这极大地降低了计算开销,并凭借更精细的特征采样显著提升了小目标检测能力,训练周期也得以大幅缩短。

ViT: 这是一个完全基于自注意力机制的视觉架构^[42],通过将图像分割成固定大小的 patches 并进行线性嵌入,结合位置编码,将其作为 Transformer 编码器的输入。

Swin Transformer: Swin Transformer^[43]是为解决 ViT 在目标检测等视觉任务中的挑战而设计的。它提出移位窗口分层框架,可以灵活地在不同尺度上建模,并保持相对于图像大小的线性计算复杂度。ViT 及其变体则证明了纯 Transformer 结构在视觉任务上的巨大潜力。

DAB-DETR, DN-DETR: 由于原始 DETR 的对象查询是随机初始化的,会导致训练速度慢且难以收敛,Liu 等人^[44]在 DAB-DETR 中将查询明确为动态锚框,并逐层迭代优化,提供了更强的空间指引。Li 等人^[45]在此基础上提出了基于查询去噪的 DN-DETR。这一方法在训练过程中引入去噪任务,通过一对一的去噪消除了原始匈牙利匹配算法中匹配不稳定问题。

Co-DETR: Zong 等人^[46]发现 DETR 中“一对一”会导致分配为正样本的查询太少,引发对 Encoder 输出的稀疏监督。为此,他们使用协同混合分配训练,提出了 Co-DETR,通过添加“一对多”标签分配的并行辅助头,极大地监督增强编码器的学习能力,最终显著提高了训练效率。

RT-DETR: RT-DETR 的提出^[47],标志着基于 Transformer 的检测器正式进入了高性能实时检测领域。RT-DETR 的核心创新在于设计了一个高效的混

合编码器,它替换了原始耗时的 Transformer 编码器,并提出了 IoU 感知的查询选择机制,以更精准地初始化对象查询。这些改进使得 RT-DETR 在保持端到端范式所有优点的同时,实现了惊人的推理速度。例如,RT-DETR-L 模型在 COCO 数据集上能够以超过 100 FPS 的速度运行,同时获得约 53% 的 AP,其速度-精度综合表现超越了同期众多优秀的 CNN 实时检测器(如 YOLO 系列)。

3 实验

3.1 数据集

ImageNet^[48]是一个用于计算机视觉识别、检测等研究的超大型图像数据库,其中的类别标签和图片涵盖了非常多在现实生活中出现的对象,目前该数据集一共包含了属于 21 841 个类别的 14 197 122 张图像 URL 和它们的根据词汇网络层次结构来人工注释的图像级二进制标签,同时,在这 1 400 多万张图片中,还有 1 034 908 张图片具有其中对象实例的边界框和类别标签注释。至今绝大多数针对视觉任务的模型都使用 ImageNet 进行训练和评估。

Pascal VOC: Pascal 视觉对象类 (VOC) 挑战 (2005 年至 2012 年)^[49-50]是早期计算机视觉界最重要的比赛之一。Pascal VOC 的两个版本主要用于目标检测: VOC07 和 VOC12,其中前者由 5k tr. 图像 +12k 注释对象组成,后者由 11k tr. 图像 +27k 注释对象构成。在这两个数据集中,对生活中常见的 20 类对象进行了注释,例如“人”、“猫”、“自行车”、“沙发”等。

MS COCO (microsoft common objects in context) 数据集^[51]是一个大规模的对象检测、分割、关键点检测的图-文数据集。该数据集由 328 000 张图像组成。MS COCO 数据集包含了 80 个不同的物体类别,涵盖了大量现实世界中的各种场景和目标,如人、动物、交通工具、食物等。因此,MS COCO 更有利于算法对现实运行环境的泛化。MS COCO 的标签中,有

针对目标检测和实例、全景分割任务的边界框和分割掩码,还有包含超过 200 000 张图像和 250 000 个标有关键点的人实例(17 个可能的关键点,如左眼、鼻子、右臀部、右脚踝),以及针对图-文多模态任务的图像和其对应的自然语言描述的图像文本对等。与 Pascal VOC 等相对较早的数据集相比,MS COCO 具有更丰富更全面的场景环境和标注信息,这些更复杂多样的信息为计算机视觉算法的发展提供了重要的帮助。

3.2 度量指标

在目标检测算法的演进过程中,评估体系的构建与完善对技术发展起到了关键的导向作用。早期的检测研究尚未形成统一的评估标准,例如行人检测领域曾采用每窗口误报数 (FPPW) 作为主要评价指标^[13]。然而,该方法因其无法准确反映完整图像性能而逐渐被淘汰^[52]。2009 年,加州理工学院提出的行人检测基准首次将评估指标转换为每张图像误报数 (FPPI),这一转变标志着评估标准开始向更贴合实际应用场景的方向演进^[52-53]。

随着 PASCAL VOC 数据集的推广,平均精度 (Average Precision, AP) 逐渐成为目标检测领域最核心的评估指标。该指标通过对不同召回率下的检测精度进行平均计算,能够综合反映检测器的分类与定位能力。具体而言,AP 定义为精度-召回率曲线下的面积,可表示为:

$$AP = \int_0^1 P(r) dr \quad (1)$$

其中 $P(r)$ 为精度随召回率变化的函数曲线。在评估过程中, 通常使用预测边界框与真实标注框之间的交并比 (Intersection over Union, IoU) 来衡量定位精度, 当 IoU 超过预设阈值 (通常取 0.5) 时即判定为正确检测。为了全面评估算法在所有类别上的表现, 研究者进一步提出平均精度均值 (mean Average Precision, mAP) 指标, 即对所有类别的 AP 值进行算术平均:

$$mAP = \frac{1}{n} \sum_{i=1}^n AP_i \quad (2)$$

其中 n 为类别总数。这一指标已成为衡量目标检测算法整体性能的基准。

2014 年 MS-COCO 数据集的发布推动了评估体系的进一步革新。该数据集提出的 AP 计算方式突破了单一 IoU 阈值的限制, 通过在 0.5 至 0.95 区间内多个 IoU 阈值上进行平均计算, 使得评估结果能够更准确地反映模型在实际复杂场景中的定位能力, 这一改进对自动驾驶等需要高精度定位的应用场景具有特别重要的意义。

评估体系的理论基础源于混淆矩阵, 其中包含真阳性 (TP)、假阳性 (FP)、假阴性 (FN) 和真阴性 (TN) 四个基本要素。基于这些要素衍生出准确率、精确率和召回率等重要指标。准确率衡量模型整体分类的正确率, 定义为:

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (3)$$

精确率反映模型预测为正例样本中真正例的比例:

$$Precision = \frac{TP}{TP + FP} \quad (4)$$

召回率则表示模型对实际正例样本的覆盖能力:

$$Recall = \frac{TP}{TP + FN} \quad (5)$$

在目标检测任务中, 精确率与召回率之间存在固有的权衡关系, 由此形成的精度-召回率曲线成为评估模型性能的重要工具。

除了上述精度指标, 计算效率评估同样不可或缺。浮点操作数 (FLOP) 作为衡量模型计算复杂度的核心指标, 表征了模型完成单次前向传播所需的计算总量, 直接影响算法在硬件平台上的部署可行性。而每秒传输帧数 (fps) 则直观反映了算法在特定硬件上的实时处理能力, 对于自动驾驶、视频监控等对实时性要求苛刻的应用场景具有决定性意义。

当前目标检测评估体系已形成多维度、多层次的完整框架, 既包含针对检测精度的 AP、mAP 等核心指标, 也涵盖衡量计算效率的 FLOP 和 fps 等实用指标。这一评估体系不仅为算法研究提供了明确的改进方向, 也为实际应用中的算法选型提供了可靠依据。未来随着检测任务复杂度的不断提升, 评估指标也将继续演进, 以更好地适应新兴应用场景的需求。

3.3 方法比较

我们对 YOLO、RetinaNet、CornerNet、CenterNet 和进行对比实验, 选取 FPS、AP、AP50 和 AP75 作为评价指标。实验结果如表 1 所示。

4 方法比较

我们对 YOLO、RetinaNet、CornerNet、CenterNet 和 RT-DETR-L 进行对比实验, 选取 FPS、AP、AP50 和 AP75 作为评价指标。实验结果如表 1 所示。

Table 1 实验结果

算法	骨干网络	FPS	AP	AP50	AP75
YOLO	DarkNet-53	20	33.0	57.9	34.4
RetinaNet	ResNeXt	5.4	40.8	61.1	44.1
CornerNet	Hourglass-104	4.1	42.1	57.8	45.3
CenterNet	Hourglass-104	7.8	45.1	63.9	49.3
RT-DETR-L	HGNetv2	108	53.0	71.3	58.0

参考文献

- [1] MCCARTHY J, MINSKY M L, ROCHESTER N, et al. A proposal for the dartmouth summer research project on artificial intelligence, august 31, 1955[J]. AI magazine, 2006, 27(4): 12-12.
- [2] HARIHARAN B, ARBELÁEZ P, GIRSHICK R, et al. Simultaneous detection and segmentation[C]//European conference on computer vision. Springer, 2014: 297-312.
- [3] HARIHARAN B, ARBELÁEZ P, GIRSHICK R, et al. Hypercolumns for object segmentation and fine-grained localization[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 447-456.
- [4] DAI J, HE K, SUN J. Instance-aware semantic segmentation via multi-task network cascades[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 3150-3158.
- [5] HE K, GKIOXARI G, DOLLÁR P, et al. Mask r-cnn [C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
- [6] KARPATHY A, FEI-FEI L. Deep visual-semantic alignments for generating image descriptions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3128-3137.
- [7] XU K, BA J, KIROUS R, et al. Show, attend and tell: Neural image caption generation with visual attention[C]//International conference on machine learning. PMLR, 2015: 2048-2057.
- [8] WU Q, SHEN C, WANG P, et al. Image captioning and visual question answering based on attributes and external knowledge[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(6): 1367-1381.
- [9] KANG K, LI H, YAN J, et al. T-cnn: Tubelets with convolutional neural networks for object detection from videos[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017, 28(10): 2896-2907.
- [10] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [11] VIOLA P, JONES M. Rapid object detection using a boosted cascade of simple features[C]//Proceedings of the 2001 IEEE computer society conference on computer vision and pattern recognition. CVPR 2001: Vol. 1. Ieee, 2001: I-I.
- [12] VIOLA P, JONES M J. Robust real-time face detection[J]. International journal of computer vision, 2004, 57(2): 137-154.
- [13] DALAL N, TRIGGS B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05): Vol. 1. Ieee, 2005: 886-893.
- [14] LOWE D G. Object recognition from local scale-invariant features[C]//Proceedings of the seventh IEEE international conference on computer vision: Vol. 2. Ieee, 1999: 1150-1157.
- [15] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60(2): 91-110.
- [16] BELONGIE S, MALIK J, PUZICHA J. Shape matching and object recognition using shape contexts[J]. IEEE transactions on pattern analysis and machine intelligence, 2002, 24(4): 509-522.
- [17] FELZENSZWALB P, MCALLESTER D, RAMANAN D. A discriminatively trained, multiscale, deformable part model[C]//2008 IEEE conference on computer vision and pattern recognition. Ieee, 2008: 1-8.
- [18] FELZENSZWALB P F, GIRSHICK R B, MCALLESTER D. Cascade object detection with deformable part models [C]//2010 IEEE Computer society conference on computer vision and pattern recognition. Ieee, 2010: 2241-2248.
- [19] MALISIEWICZ T, GUPTA A, EFROS A A. Ensemble of exemplar-svms for object detection and beyond[C]//2011 International conference on computer vision. IEEE, 2011: 89-96.
- [20] FELZENSZWALB P F, GIRSHICK R B, MCALLESTER D, et al. Object detection with discriminatively trained part-based models[J]. IEEE transactions on pattern analysis and machine intelligence, 2009, 32(9): 1627-1645.
- [21] GIRSHICK R, FELZENSZWALB P, MCALLESTER D. Object detection with grammar models[J]. Advances in neural information processing systems, 2011, 24.
- [22] GIRSHICK R B. From rigid templates to grammars: Object detection with structured models[M]. The University of Chicago, 2012.
- [23] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural

- networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [24] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [25] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [26] GIRSHICK R, DONAHUE J, DARRELL T, et al. Region-based convolutional networks for accurate object detection and segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 38(1): 142-158.
- [27] HE K, ZHANG X, REN S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition [J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [28] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [29] REN S, HE K, GIRSHICK R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [30] CAI Z, VASCONCELOS N. Cascade r-cnn: Delving into high quality object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6154-6162.
- [31] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [32] REDMON J, FARHADI A. Yolov3: An incremental improvement[A]. 2018.
- [33] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C]//European conference on computer vision. Springer, 2016: 21-37.
- [34] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [35] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [36] CHEN Q, WANG Y, YANG T, et al. You only look one-level feature[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13039-13048.
- [37] TIAN Z, SHEN C, CHEN H, et al. Fcos: Fully convolutional one-stage object detection[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 9627-9636.
- [38] LAW H, DENG J. Cornernet: Detecting objects as paired keypoints[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 734-750.
- [39] ZHOU X, WANG D, KRÄHENBÜHL P. Objects as points [A]. 2019.
- [40] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]//European conference on computer vision. Springer, 2020: 213-229.
- [41] ZHU X, SU W, LU L, et al. Deformable detr: Deformable transformers for end-to-end object detection[A]. 2020.
- [42] DOSOVITSKIY A. An image is worth 16x16 words: Transformers for image recognition at scale[A]. 2020.
- [43] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [44] LIU S, LI F, ZHANG H, et al. Dab-detr: Dynamic anchor boxes are better queries for detr[A]. 2022.
- [45] LI F, ZHANG H, LIU S, et al. Dn-detr: Accelerate detr training by introducing query denoising[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 13619-13627.
- [46] ZONG Z, SONG G, LIU Y. Detsr with collaborative hybrid assignments training[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 6748-6758.
- [47] ZHAO Y, LV W, XU S, et al. Detsr beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.

- 2024: 16965-16974.
- [48] DENG J, DONG W, SOCHER R, et al. Imagenet: A large-scale hierarchical image database[J]. CVPR, 2009.
- [49] EVERINGHAM M, VAN GOOL L, WILLIAMS C K, et al. The pascal visual object classes (voc) challenge[J]. International journal of computer vision, 2010, 88(2): 303-338.
- [50] EVERINGHAM M, ESLAMI S A, VAN GOOL L, et al. The pascal visual object classes challenge: A retrospective [J]. International journal of computer vision, 2015, 111(1): 98-136.
- [51] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context[J]. ECCV, 2014.
- [52] DOLLÁR P, WOJEK C, SCHIELE B, et al. Pedestrian detection: A benchmark[C]//2009 IEEE conference on computer vision and pattern recognition. IEEE, 2009: 304-311.
- [53] DOLLAR P, WOJEK C, SCHIELE B, et al. Pedestrian detection: An evaluation of the state of the art[J]. IEEE transactions on pattern analysis and machine intelligence, 2011, 34(4): 743-761.

Han Fangjing, M.S., is a graduate student. Her research interests include federated graph learning.